Transformer

Attention is all you need, 2017 논문에서 나온 모델

기존의 Seq2Seq 구조인 encoder-decoder 형식을 따름

특이점 : Attention 만으로 모델을 구현

1. Attention 배경 설명

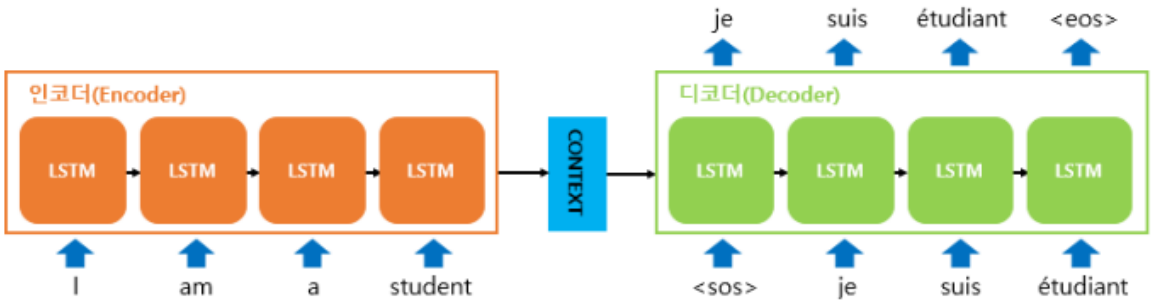

본 그림의 기존의 번역 Task를 수행하는 Encoder-Decoder, 즉 Seq2Seq 모델 중 하나임.

기존 방식의 문제점

1. Context Vector에 많은 Load가 실리게 됨. (정보의 손실이 발생함)
2. Vanshing gradient 문제 발생

이를 해결하기 위해 Attention concept이 등장함

Attention

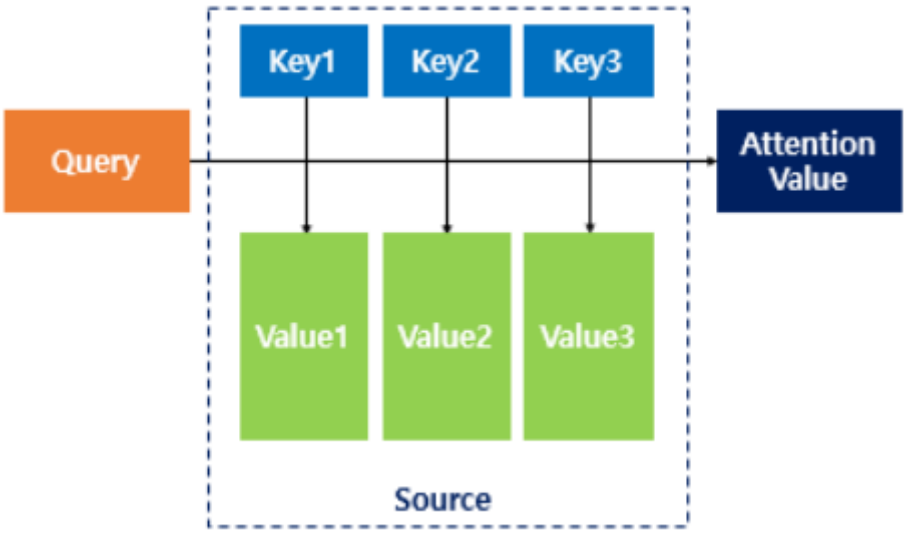

Attention(Q,K,V)=Attention Value

Query와 Key 간의 유사도를 계산한 후에 이를 Value에 반영해서, 이들을 다 더해서 Attention value를 계산해냄.

여러 가지 종류의 Attention이 있지만, Dot Product Attention을 위주로 설명하겠음.

Dot Product Attention

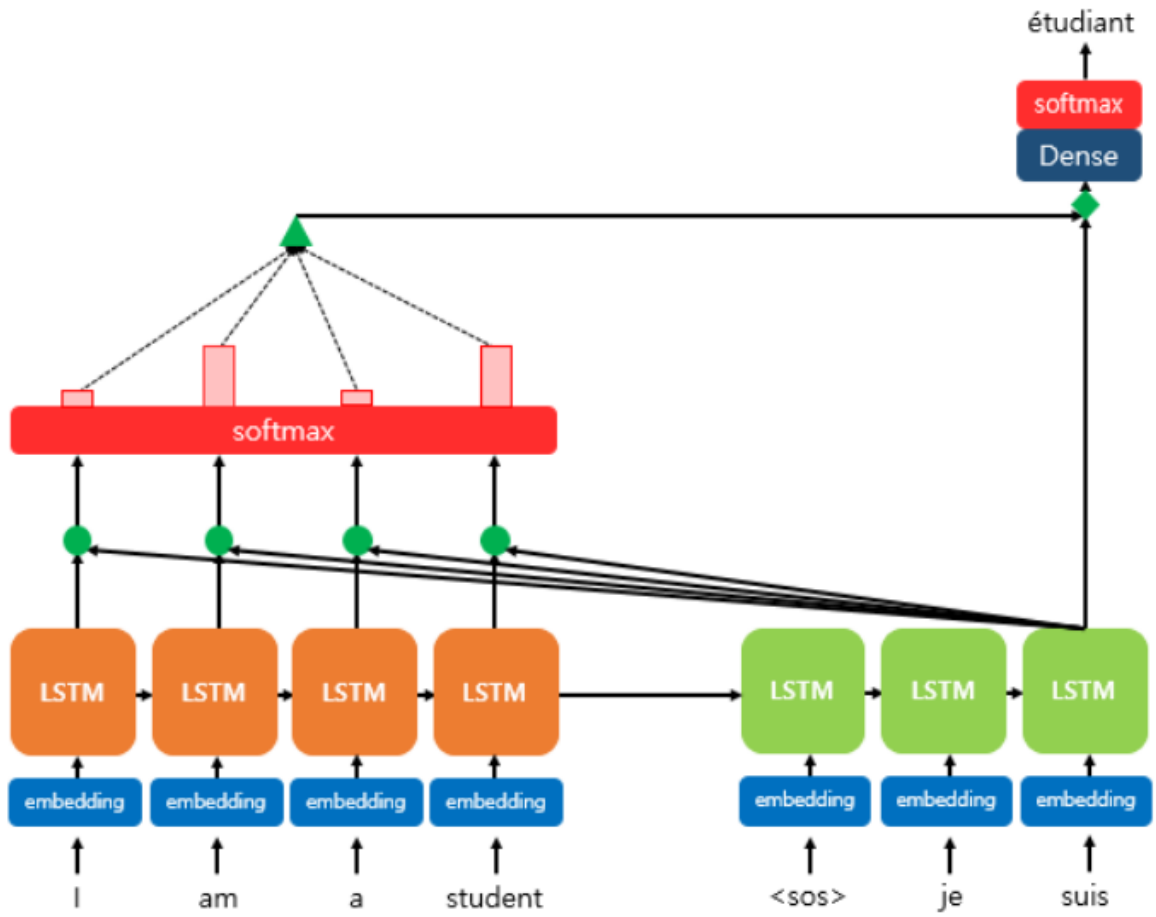

기존의 seq2seq 모델과 동일한 형태에 Attention 개념이 들어가게 된 것임.

Attention이란 Decoder의 각 step의 hidden state를 Query로 두고, Encoder의 각 step의 output을 Key,Value로 둔다

식으로 표현하면 Attention value = Softmax(Q K.T) K

이를 의미적으로 풀어내면, suis를 예로 들어보자. suis와 encoder의 값들(영어) 간의 유사도(Attention score)를 계산한 후에, 이에 softmax를 취한다.(Attention Distribution) 그리고 이 값들을 각각에 대응되는 Value 값에 곱한 후에 이를 다 더한다. 이렇게 되면 suis와 유사한 영어 단어의 유사도를 반영한 영어 단어들의 합으로 결과값을 산출하게 됨.

이렇게 Attention을 활용하게 되면 Context vector에 많은 Load가 실리는 문제를 해결할 수 있고, vanishing gradient에 관해서는 Attention value는 먼 거리에 있는 값들에 대해서도 동일하게 적용될 수 있기 때문에 보완해낼 수 있다.

Transformer는 이러한 Attention 만을 가지고 Seq2Seq 모델을 구현해보자라는 것이다

2. Transformer

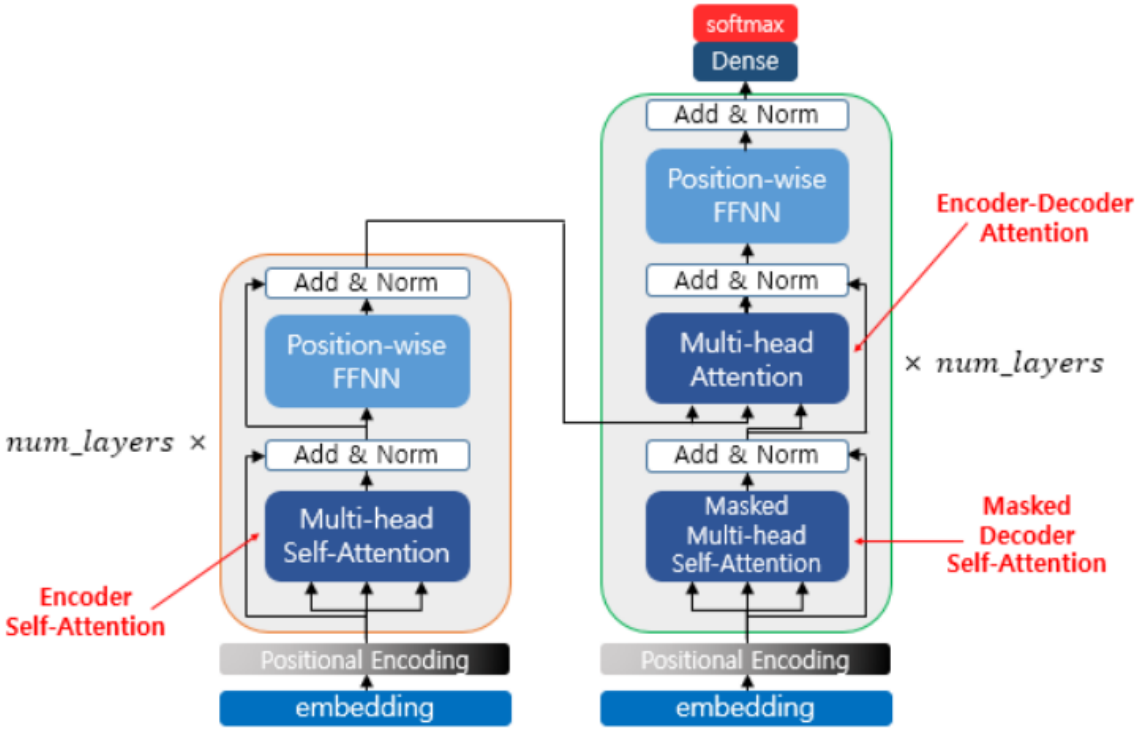

Transformer의 핵심은, **Self Attention**과 **Multi head attention**이라고 할 수 있다.

Attention

Transformer는 Attention만으로만 구성된 Seq2Seq 모델이라고 할 수 있다.

기존의 Seq2Seq 모델의 경우 RNN+Attention구조였는데, 이러한 RNN의 경우엔 Auto regressive 성질을 지니고 있기 때문에 병렬처리가 힘들다. 이렇게 되면 GPU 등을 효율적으로 활용할 수 없기 때문에 Attention 만으로 모델을 만들어보자라고 해서 나온 것이 Transformer이다.

본 논문에서 나오는 Attention의 종류는 3가지이다.

1. Self Attention (Encoder)
2. Encoder-Decoder Attention
3. Masked Self Attention (Decoder)

1. Self Attention은 말 그대로, Query, Key, Value가 동일한 source에서 나온 값이다.

ex) 나는 학교에 간다

임베딩 차원을 5라고 한다면, 여기에서 Self Attention 중에서 Attention을 scaled dot product로 한다면 Softmax(QK.T)V에서 QK.T의 결과가 맨 우측의 값이 된다.

이제 여기에 Softmax를 취하고 V와 행렬 곱을 해주면, 결과가 나오게 된다.

의미론 적으로 본다면, 각 Token들이 자기 자신을 포함한 다른 Token 간의 유사도를 반영한 임베딩 벡터의 합이라고 할 수 있겠다.

2. Encoder - Decoder Attention은 Query가 Decoder의 Output이고, Key, Value가 Encoder의 Output인 기존 RNN+Attention에서 Attention이 했던 역할이라고 하면 된다. 즉 Decoder에서 output을 내기 위해서 Encoder 부분을 참조한다는 의미로 보시면 될 것 같다.

3. Masked Self Attention은 Decoder 부분에서 쓰인다.

예시, I go to the school

실제로 decoder에서 I에 해당되는 token을 넣었을 때에 I는 뒤에 따라오는 문장에 대한 정보는 없다. 이렇기 때문에 mask를 씌우게 된다. mask는 즉, 다음에 올 문장에 대한 정보를 못보게 하기 위함이다.

Multi Head Attention

Multi Head Attention은 다양한 관점에서 Attention 작업을 수행하는 것으로서,

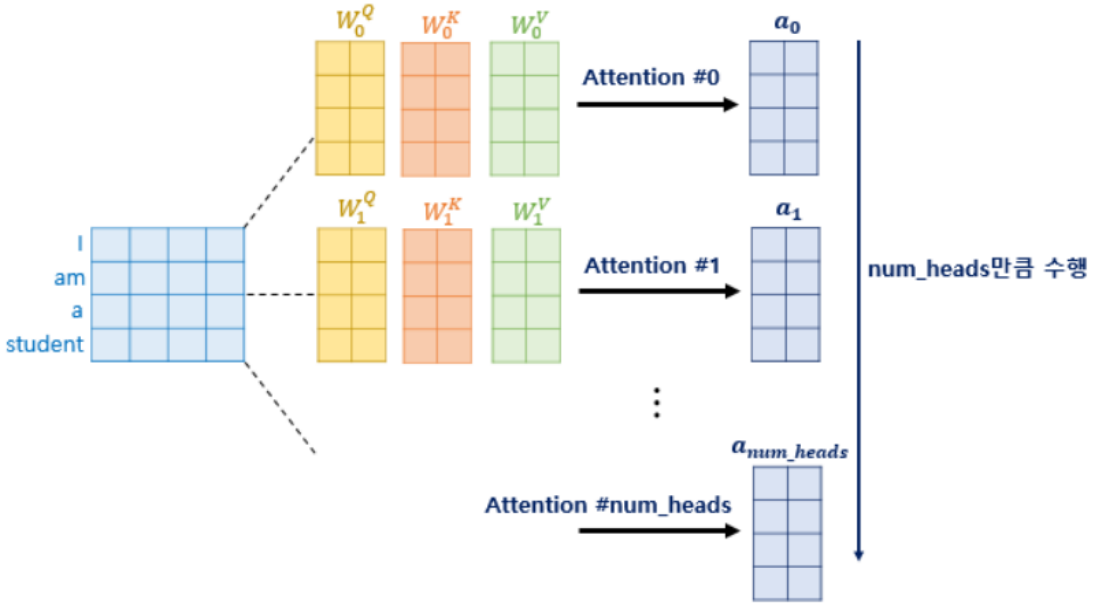

num_heads만큼 수행을 하게 됩니다. 그림을 보게 되시면 a0,a1, .. a_num_heads만큼 attention value가 나오게 됩니다. 이제 이를 concat 해서 최종적인 attention value를 산출하게 됩니다.

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, ..., \text{head}_\text{h})W^O$$
$$\text{where head}_\text{i} = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

Where the projections are parameter matrices $W_i^Q \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$, $W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$ and $W^O \in \mathbb{R}^{hd_v \times d_{\text{model}}}$.